Détection d'anomalies dans les séries temporelles

Analyse fréquentielle et seuillage statistique

Application aux données NAB realTweets

TIPE 2025 – CPGE MPI

Plan

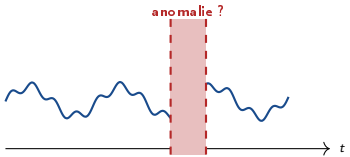
Problématique

Question centrale

Comment détecter automatiquement un comportement anormal dans une série temporelle, à partir d'un historique de référence, **en procédant du plus évident au plus subtil** ?

Le problème fondamental :

- face à un seul signal, impossible de conclure ;
- toutes les fluctuations ne sont pas des anomalies ;
- il faut une *définition quantitative* du normal.



Sans référence : impossible de décider.

Réponse méthodologique

Construire un **modèle statistique du comportement normal** sur un historique, puis comparer tout nouveau segment à ce modèle.

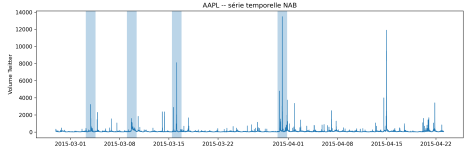
Base de données : NAB *realTweets*

NAB – Numenta Anomaly Benchmark

- Benchmark de référence en détection d'anomalies.
- Anomalies **étiquetées** dans `combined_windows.json` : on sait exactement où elles se situent.

Sous-ensemble : realTweets

- 10 séries – volumes de mentions Twitter par titre boursier :
  AAPL, AMZN, CRM, CVS, FB, GOOG, IBM, KO, PFE, UPS ;
- $\approx 15\,000$ points par série, cadence 5 min ;
- Anomalies = pics lors d'annonces (résultats, fusions…).



Série AAPL (Apple) – série de test principale.

Zones colorées = anomalies étiquetées NAB.

Ce que NAB apporte

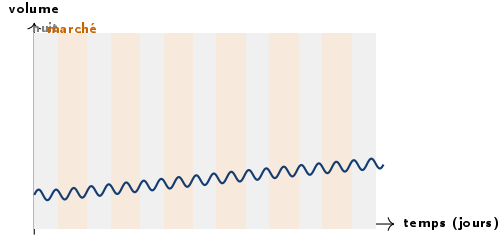
Les labels réels remplacent toute injection artificielle.

Les 10 séries sont-elles comparables ?

Observation : chaque titre a son propre niveau absolu de mentions (AAPL est bien plus discuté que KO). Les séries ne sont donc **pas directement comparables** en valeur brute.

Ce qui est commun hors anomalie :

- **Rythme circadien :** les mentions montent pendant les heures de marché américain (9h–16h EST) et chutent la nuit. Ce cycle produit une structure *quasi-sinusoïdale* sur plusieurs jours.
- **Nature du bruit :** fluctuations aléatoires de même type.



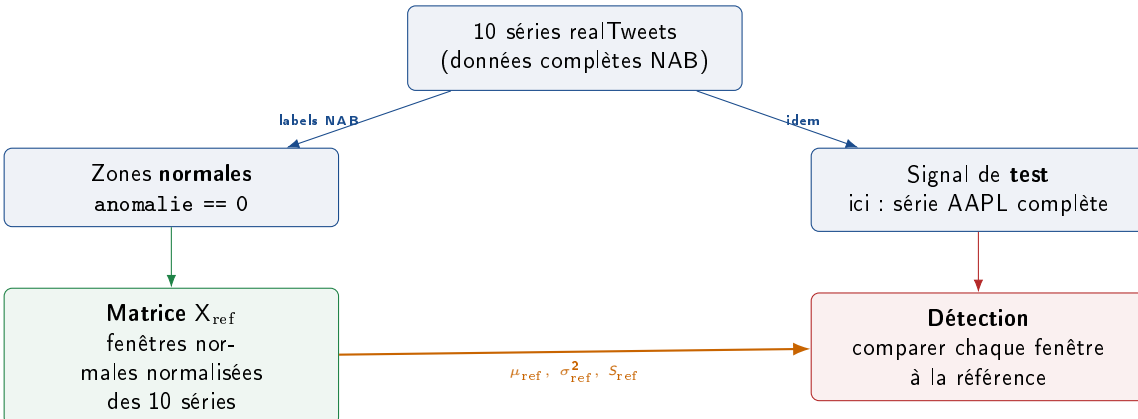
Cycle journalier commun aux 10 titres

Solution : normalisation par série

Avant de construire la référence, chaque série est **normalisée** (centrage-réduction) sur ses zones normales :

Note : donnée = volume de mentions, **pas** la valeur boursière du titre.

Stratégie générale



La matrice de référence X_{ref} – Construction

Principe : on découpe les zones normales de *toutes* les séries (après normalisation) en fenêtres de longueur W, et on les empile ligne par ligne :

$$X_{\text{ref}} = \underbrace{\begin{pmatrix} \leftarrow & x_1 & \rightarrow \\ \leftarrow & x_2 & \rightarrow \\ & \vdots & \\ \leftarrow & x_K & \rightarrow \end{pmatrix}}_{K \text{ fenêtres normales}} \in \mathbb{R}^{K \times W}$$

Chaque ligne $x_k = (x_k(1), \ldots, x_k(W)) \in \mathbb{R}^W$ est une fenêtre normale de longueur W.

Composition de X_{ref}

Les lignes proviennent des **10 séries mélangées**. Par exemple, les lignes 1 à 1200 viennent d'AAPL, les lignes 1201 à 2400 d'AMZN, etc. En tout : $K \approx 12\,000$ fenêtres.

Ce qu'on en extrait

On ne manipule pas la matrice directement. On en calcule les statistiques globales : μ_{ref}, σ^2_{ref}, S_{ref} – qui serviront de référence du normal.

Loi faible des grands nombres – Rappel

Théorème (Loi faible des grands nombres)

Soient $Y_1, Y_2, \ldots, Y_K$ des variables aléatoires **indépendantes et identiquement distribuées** (i.i.d.) d'espérance $\mathbb{E}[Y_1] = m$ finie et de variance finie. Alors, pour tout $\varepsilon > 0$:

$$P\left(\left| \frac{1}{K} \sum_{k=1}^{K} Y_k \; - \; m \right| > \varepsilon \right) \xrightarrow[K \to +\infty]{} 0.$$

La moyenne empirique **converge en probabilité** vers l'espérance théorique.

Notations utilisées dans la suite :

- K : nombre total de fenêtres normales dans $\mathrm{X}_{\mathrm{ref}}$
- W : longueur d'une fenêtre (nombre de points)
- μ_{ref} : moyenne empirique sur toutes les cellules de $\mathrm{X}_{\mathrm{ref}}$ (scalaire)
- $\sigma^2_{\mathrm{ref}} = \sigma^2_{\mathrm{ref}}$: variance empirique globale (scalaire)
- $\sigma_{\mathrm{ref}} = \sqrt{\sigma^2_{\mathrm{ref}}}$: écart-type de référence
- μ^*, $(\sigma^*)^2$: espérance et variance théoriques du processus normal

Application de la LGN – Hypothèse et validité

Hypothèse nécessaire :
La LGN requiert que les Y_k soient i.i.d. de même espérance m. Ici, les Y_k sont les valeurs des cellules $x_k(j)$ de $\mathrm{X}_{\mathrm{ref}}$.

Problème sans normalisation

Les 10 séries ont des niveaux absolus différents (ex : AAPL $\gg$ KO en volume brut). Empiler directement les fenêtres brutes donnerait un μ_{ref} qui n'est que la moyenne du mélange – biaisé par les séries les plus actives.

Après normalisation par série

Chaque série s est centrée-réduite sur ses zones normales. Les K fenêtres normalisées ont alors, par construction, même espérance $\mu^* = 0$ et variance $(\sigma^*)^2 = 1$. **L'hypothèse i.i.d. est alors raisonnable.**

On calcule :

$$\mu_{\mathrm{ref}} = \frac{1}{KW} \sum_{k=1}^{K} \sum_{j=1}^{W} x_k(j) \xrightarrow{K\to\infty} \mu^*$$

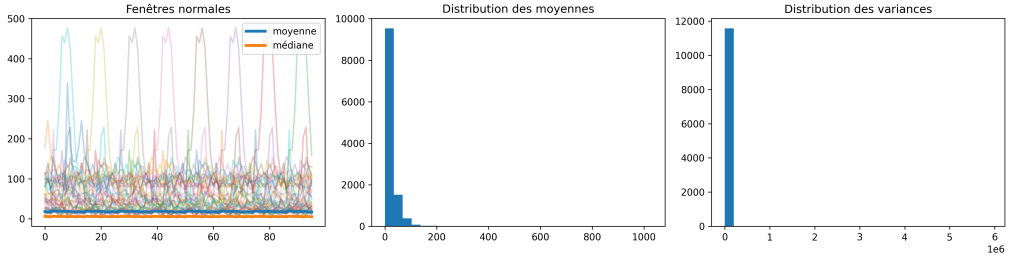
$$\sigma^2_{\mathrm{ref}} = \frac{1}{KW} \sum_{k=1}^{K} \sum_{j=1}^{W} \left(x_k(j) - \mu_{\mathrm{ref}}\right)^2 \xrightarrow{K\to\infty} (\sigma^*)^2$$

En pratique

$K \approx 12\,000$ fenêtres.
L'erreur standard $\propto 1/\sqrt{K}$ est statistiquement très faible.

Les estimateurs μ_{ref} et σ^2_{ref} sont donc très fiables.

Ce que la matrice de référence représente



Gauche : **superposition de quelques dizaines de fenêtres normales (normalisées). Le rythme circadien commun est visible.** Centre : **distribution des moyennes $\hat{\mu}_k$ — concentrée autour de 0 après normalisation.** Droite : **distribution des variances $\hat{\sigma}_k^2$ — concentrée autour de 1. Ces deux distributions valident l'hypothèse i.i.d.**

Moyenne vs Médiane – Robustesse (1/2)

Scénario : parmi les K fenêtres de référence, une fenêtre anormale de valeur $M \gg \mu^*$ s'est glissée (anomalie non étiquetée dans NAB). Quel impact sur nos estimateurs ?

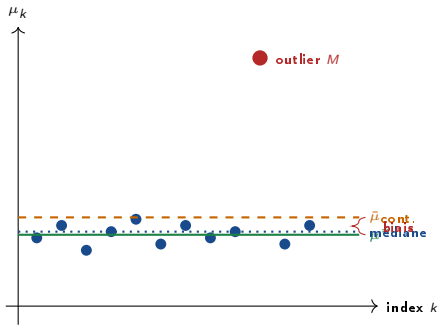
Impact sur la moyenne arithmétique :

$$\bar{\mu}_{\text{contaminé}} = \frac{(K-1)\mu^* + M}{K} = \mu^* + \underbrace{\frac{M - \mu^*}{K}}_{\text{biais}}$$

Le biais est $O(M/K)$: il tend vers 0 quand K est grand, mais peut être significatif si M est très extrême.

Impact sur la médiane :
La médiane est la valeur d'ordre $\lceil K/2 \rceil$ dans le classement. Si $M \gg \mu^*$, l'outlier se retrouve en bout de classement et **ne déplace pas** la valeur centrale.

Moyenne vs Médiane – Robustesse (2/2)



Point de rupture

La médiane supporte jusqu'à 50% d'outliers
sans être déplacée.

La moyenne est sensible dès le premier outlier
(*breakdown point* $= 0\%$).

Décision pratique

Les historiques NAB sont quasi-propres et K est grand ($\approx 12\,000$).

On utilise la **moyenne** : simple et suffisante ici.

La médiane serait préférable si l'historique contenait beaucoup d'anomalies non étiquetées.

Code – Construction de la matrice de référence

```
# Parametres : W = taille fenetre, H = pas de glissement
# TICKERS = ["AAPL", "AMZN", "CRM", "CVS", "FB", "GOOG", "IBM", "KO", "PFE", "UPS"]

ref_fenetres = []

for ticker in TICKERS:
    df     = series[ticker]
    values = df["value"].values.astype(float)
    labels = df["anomalie"].values   # 0 = normal, 1 = anomalie (label NAB)

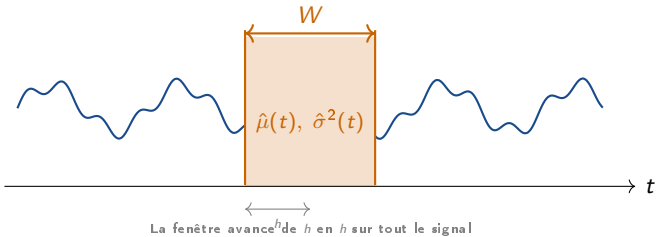
    # Normalisation de chaque serie sur ses zones normales
    mu_s  = values[labels == 0].mean()
    sig_s = values[labels == 0].std()
    values_norm = (values - mu_s) / sig_s  # centrage-reduction

    for t in range(0, len(values_norm) - W, H):
        fen = values_norm[t : t + W]
        lab = labels[t : t + W]
        if np.all(lab == 0):                  # fenetre totalement normale
            ref_fenetres.append(fen)

X_ref = np.array(ref_fenetres)   # (K, W), ex. (12000, 96)

# Statistiques de reference (cf. LGN : convergent vers mu*=0, sigma*=1)
mu_ref  = X_ref.mean()           # proche de 0
var_ref = X_ref.var()            # proche de 1
sig_ref = X_ref.std()
```

Étape 1 – Principe de la fenêtre glissante



Pour chaque position $t = 0, h, 2h, \ldots$:

$$\hat{\mu}(t) = \frac{1}{W} \sum_{k=0}^{W-1} x(t+k), \qquad \hat{\sigma}^2(t) = \frac{1}{W} \sum_{k=0}^{W-1} \big(x(t+k) - \hat{\mu}(t)\big)^2$$

On compare ensuite $\hat{\mu}(t)$ et $\hat{\sigma}^2(t)$ aux statistiques de référence μ_{ref} et σ^2_{ref}.

Inégalité de Bienaymé-Tchebychev – Application (1/2)

Rappel de l'inégalité :

Pour toute variable aléatoire X d'espérance $\mu = \mathbb{E}[X]$ et de variance finie $\sigma^2 = \mathrm{Var}(X) < +\infty$, et pour tout réel $k > 0$:

$$\boxed{P\big(|X - \mu| \geq k\sigma\big) \;\leq\; \frac{1}{k^2}}$$

Application à notre détecteur :

On applique cela à la moyenne glissante $\hat{\mu}(t)$. Si la fenêtre $[t, t + W[$ est *normale*, alors elle est issue du même processus que X_{ref}, donc $\hat{\mu}(t)$ doit être proche de μ_{ref}.

L'inégalité donne une borne sur la probabilité de fausse alarme :

$$P\big(|\hat{\mu}(t) - \mu_{\mathrm{ref}}| \geq k\,\sigma_{\mathrm{ref}}\big) \;\leq\; \frac{1}{k^2}$$

Critère de détection – Étape 1

On signale la fenêtre comme **suspecte** si :

$$|\hat{\mu}(t) - \mu_{\mathrm{ref}}| > k\,\sigma_{\mathrm{ref}} \quad \text{ou} \quad \hat{\sigma}^2(t) > 2\,\sigma_{\mathrm{ref}}^2$$

Inégalité de Bienaymé-Tchebychev – Choix de $k = 3$ (2/2)

La borne $1/k^2$ décroît rapidement avec k :

k	borne $P \leq 1/k^2$
1	100%
2	25%
3	11%
4	6%
5	4%

Limite de l'étape 1 – Ce que la moyenne ne voit pas

Contre-exemple : deux signaux sur $[0, W-1]$

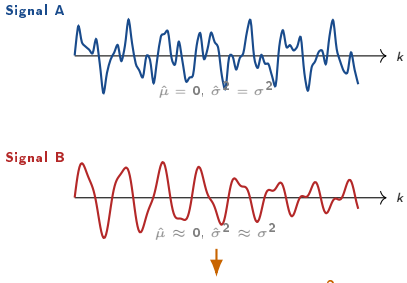
Signal A (normal) : bruit blanc gaussien

$$A(k) = \varepsilon_k, \quad \varepsilon_k \sim \mathcal{N}(0, \sigma^2)$$

Signal B (anomalie cachée) :

$$B(k) = \sin\left(\frac{2\pi f_0 k}{W}\right) + \varepsilon'_k$$

avec $\varepsilon'_k \sim \mathcal{N}(0, \sigma^2)$ et f_0 telle que $\sum_k \sin(2\pi f_0 k/W) = 0$.

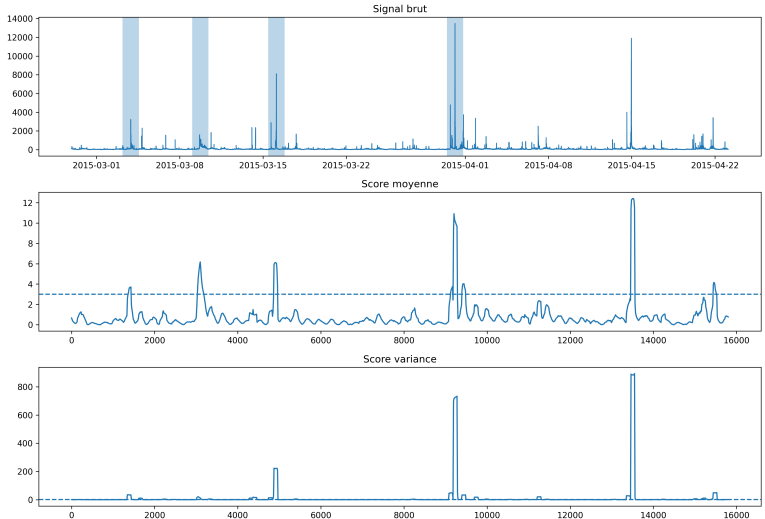


Résultat

$\mathbb{E}[A] = 0 = \mathbb{E}[B]$ et $\mathrm{Var}(A) \approx \mathrm{Var}(B)$

L'étape 1 ne les distingue pas.
Pourtant B contient une oscillation à f_0 absente du signal normal.
⇒ **Motivation pour l'étape 2 (Fourier).**

Détection étape 1 – Série AAPL (Apple, données NAB)



Haut : **signal AAPL brut (normalisé) – zones colorées = anomalies NAB (labels de référence)**. Milieu : **score de moyenne** $|\hat{\mu}(t) - \mu_{\text{ref}}|/\sigma_{\text{ref}}$ **– seuil** $k = 3$ **(pointillé)**. Bas : **score de variance** $\hat{\sigma}^2(t)/\sigma^2_{\text{ref}}$ **– seuil à 2.**

Code – Étape 1 (série AAPL)

```
# sig = serie AAPL normalisee (values_norm du ticker "AAPL")

def detection_etape1(sig):
    pos, susp = [], []
    scores_mu, scores_var = [], []

    for t in range(0, len(sig) - W, H):
        fen     = sig[t : t + W]
        mu_hat  = fen.mean()
        var_hat = fen.var()

        # Score en nombre de sigma (cf. Bienayme-Tchebychev)
        s_mu  = abs(mu_hat - mu_ref) / sig_ref    # |mu_hat - mu_ref| / sigma_ref
        s_var = var_hat / var_ref                  # rapport de variances

        pos.append(t)
        scores_mu.append(s_mu)
        scores_var.append(s_var)

        if s_mu > 3 or s_var > 2:                 # k=3 pour mu, seuil x2 pour var
            susp.append(t)

    return np.array(pos), susp, np.array(scores_mu), np.array(scores_var)

pos, susp1, sc_mu, sc_var = detection_etape1(values_norm_AAPL)
print(f"Etape 1 : {len(susp1)} fenetres suspectes sur {len(pos)}")
```

Complexité

Transformée de Fourier discrète (DFT) – Définition

Soit $x = (x(0), \ldots, x(W-1))$ une fenêtre de taille W centrée. Sa **Transformée de Fourier Discrète** est :

$$\hat{X}(f_j) = \sum_{k=0}^{W-1} x(k)\, e^{-2i\pi jk/W}, \qquad j = 0, 1, \ldots, \lfloor W/2 \rfloor$$

Les fréquences discrètes sont $f_j = j/W$ (en cycles par point).

Le **spectre de puissance** à la fréquence f_j :

$$\boxed{S(f_j) = \frac{1}{W} \left|\hat{X}(f_j)\right|^2}$$

Théorème de Parseval

$$\sum_{k=0}^{W-1} |x(k)|^2 \;=\; W \sum_{j=0}^{\lfloor W/2 \rfloor} S(f_j)$$

La puissance totale se conserve.

Interprétation

- $S(f_j)$: puissance à la fréquence f_j
- un pic soudain : énergie sur toutes les fréquences
- une oscillation anormale : pic à f_0

Spectre de référence et distance spectrale

Spectre de référence :

$$S_{\text{ref}}(f_j) = \frac{1}{K} \sum_{k=1}^{K} S_k(f_j)$$

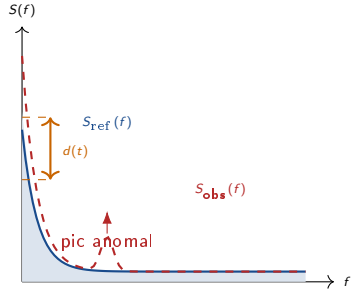
Moyenne des spectres de toutes les fenêtres normales de X_{ref}.

Distance spectrale (fenêtre de test vs référence) :

$$d(t) = \sqrt{\sum_{j=0}^{\lfloor W/2 \rfloor} \left(S_{\text{obs}}(f_j) - S_{\text{ref}}(f_j)\right)^2}$$

Seuil calibré empiriquement

On calcule $d_1, \ldots, d_K$ sur les fenêtres normales.



Limite de Fourier

La DFT donne une information **globale** sur la fenêtre. Elle ne localise pas l'anomalie dans le temps. ⇒ Objet de l'étape 3.

Pourquoi Fourier est plus discriminant que la variance

Théorème de Wiener-Khinchin

Pour un signal stationnaire, le spectre de puissance $S(f)$ est la transformée de Fourier de la fonction d'autocorrélation $R(\tau) = \mathbb{E}[x(t)\,x(t+\tau)]$:

$$S(f) = \sum_{\tau=-\infty}^{+\infty} R(\tau)\, e^{-2i\pi f \tau}$$

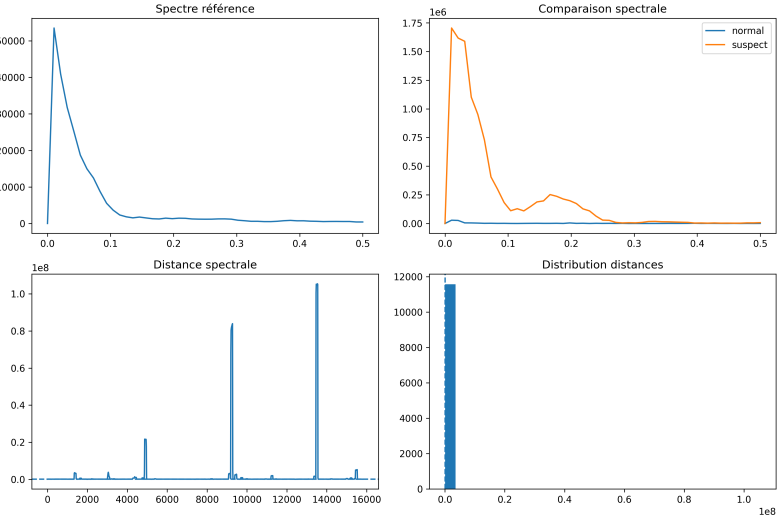
Ce que chaque outil capture :

- Moyenne $\hat{\mu}$: $\mathbb{E}[x]$ – moment d'ordre 1
- Variance $\hat{\sigma}^2$: $R(0)$ – un seul coefficient
- Spectre $S(f)$: **toute la suite** $\big(R(\tau)\big)_{\tau \geq 0}$

Conséquence

Une anomalie qui ne change ni $\mathbb{E}[x]$ ni $R(0)$ (même moyenne, même variance), mais qui modifie $R(\tau)$ pour $\tau \neq 0$, est **invisible à l'étape 1** mais **visible dans le spectre**.

Analyse spectrale – Série AAPL (Apple, données NAB)



Haut gauche : spectre de référence $S_{\mathrm{ref}}(f)$. Haut droite : spectre d'une fenêtre normale (bleu) vs suspecte (orange) – la puissance basse fréquence explose lors de l'anomalie. Bas gauche : distance spectrale $d(t)$ – les pics coïncident avec les anomalies NAB. Bas droite : distribution de d sur $\mathbf{X}_{\mathrm{ref}}$ –

Code – Étape 2 : analyse spectrale

```
def spectre(seg):
    s    = seg - seg.mean()           # centrage (retirer la composante DC)
    X    = rfft(s)                    # DFT reelle : retourne W//2+1 coefficients
    freq = rfftfreq(len(seg), d=1)
    return freq, np.abs(X)**2 / len(seg)    # spectre de puissance S(f)

# Spectre de reference : moyenne colonne par colonne sur X_ref
S_ref = np.mean([spectre(row)[1] for row in X_ref], axis=0)

# Distance spectrale euclidienne : ecart entre S_obs et S_ref
def dist_spec(seg):
    _, S = spectre(seg)
    return np.sqrt(np.sum((S - S_ref)**2))

# Seuil calibre sur les donnees normales : quantile 95%
d_ref = np.array([dist_spec(row) for row in X_ref])
tau   = np.quantile(d_ref, 0.95)      # au plus 5% de fausses alarmes

# Etape 2 : filtrer les suspects de l'etape 1 par le critere spectral
susp2 = [t for t in susp1 if dist_spec(values_norm_AAPL[t:t+W]) > tau]

print(f"Etape 2 : {len(susp2)} confirmes / {len(susp1)} suspects etape 1")
```

Réduction des fausses alarmes

Les fenêtres de susp1 dont la structure fréquentielle est cohérente avec la référence sont éliminées.

Étape 3 – Localisation par intersection de fenêtres

Problème : une fenêtre suspecte $[t_0, t_0 + W[$ donne un intervalle de taille W, pas un instant précis.

Observation clé : si deux fenêtres consécutives (décalées de h) sont toutes deux suspectes, l'anomalie est dans leur intersection.

Propriété d'intersection

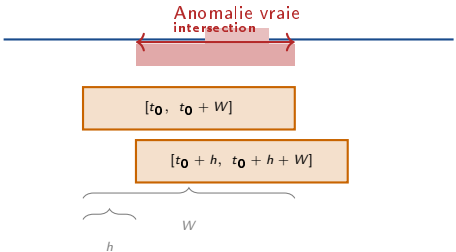
Si $[t_0, t_0 + W]$ et $[t_0 + h, t_0 + h + W]$ sont suspectes :

$$\mathcal{A} \subset [t_0 + h,\ t_0 + W]$$

Avec p fenêtres consécutives :

$$\mathcal{A} \subset [t_0 + (p-1)h,\ t_0 + W]$$

Précision : $(W - (p-1)h) \times 5$ min.



Plus h est petit $\Rightarrow$ localisation plus précise
(mais plus de calcul).

Algorithme de localisation – Principe

Algorithme (intersection de groupes consécutifs) :

1. Trier les fenêtres suspectes (après étape 2) : $t_1 < t_2 < \cdots < t_m$.
2. Regrouper les positions consécutives : deux positions t_i et t_{i+1} appartiennent au même groupe si $t_{i+1} - t_i \leq h$.
3. Pour chaque groupe $\mathcal{G} = \{t_1^g, t_2^g, \ldots, t_p^g\}$ de p fenêtres consécutives, l'intersection donne :

$$\text{début anomalie} = t_1^g + (p-1)\,h, \qquad \text{fin anomalie} = t_1^g + W$$

La précision en temps est $\big(W - (p-1)h\big) \times 5$ min.

Complexité :

- Calcul de $d(t)$ pour les suspects : $O(m \cdot W)$ où $m = |\text{susp1}|$
- Regroupement : $O(m)$ (un seul passage sur la liste triée)
- **Total étape 3 :** $O(m \cdot W) \ll O(N \cdot W/h)$ de l'étape 1

Algorithme de localisation – Code

```
def localiser(suspects):
    if not suspects:
        return []
    groupes, g = [], [suspects[0]]

    for i in range(1, len(suspects)):
        if suspects[i] - suspects[i-1] <= H:   # consecutifs : meme groupe
            g.append(suspects[i])
        else:
            groupes.append(g)
            g = [suspects[i]]
    groupes.append(g)

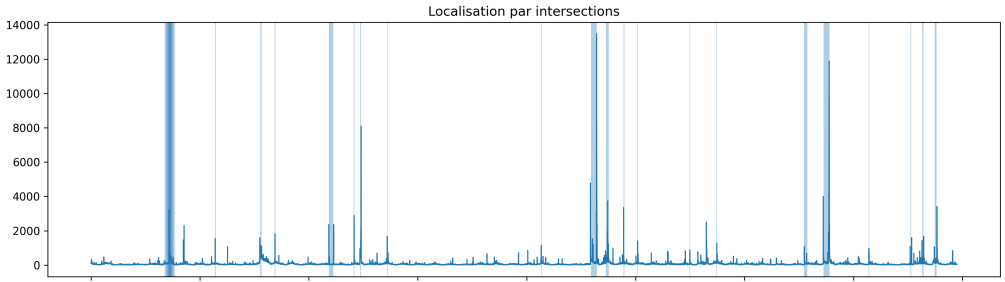
    locs = []
    for g in groupes:
        p   = len(g)         # nb de fenetres consecutives suspectes
        t0  = g[0]           # position de la premiere fenetre du groupe
        deb = t0 + (p-1)*H   # debut de l'intersection
        fin = t0 + W         # fin de l'intersection
        prec = (fin - deb) * 5   # precision en minutes (cadence 5 min)
        locs.append((deb, fin, prec))
    return locs

locs = localiser(susp2)
for deb, fin, prec in locs:
    print(f"Anomalie localisee dans [{deb}, {fin}], precision = {prec} min")
```

Pas de dichotomie

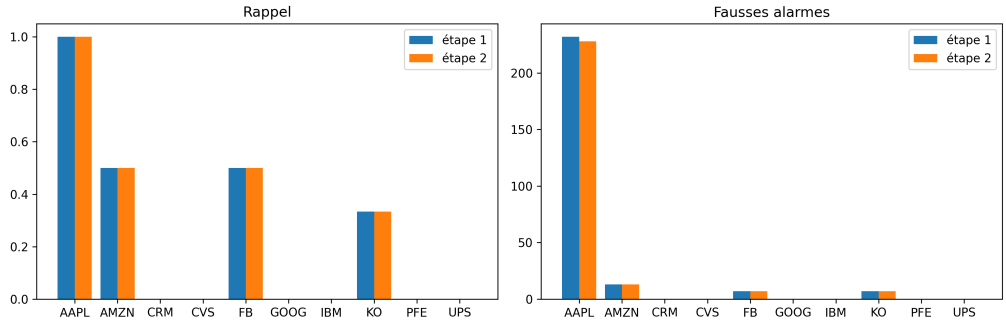
On exploite directement la structure de la liste triée, sans $O(W \log W)$

Localisation – Série AAPL (Apple, données NAB)



Zones claires : fenêtres suspectes initiales (taille W). Zones sombres : résultat de l'intersection (localisation affinée). Précision $= (W - (p-1)h) \times$ **5 min.**

Évaluation sur les 10 séries NAB realTweets



Gauche : **rappel (proportion d'anomalies NAB détectées) — étape 1 vs étape 2.** Droite : **nombre de fausses alarmes — l'étape 2 réduit drastiquement les faux positifs.**

Interprétation des résultats

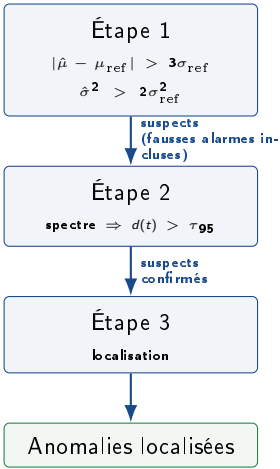
Étape 1 (moyenne + variance) :

- forte sensibilité : les pics de volume sont captés ;
- mais **nombreuses fausses alarmes** : le signal Twitter fluctue naturellement beaucoup.

Étape 2 (spectre de Fourier) :

- filtre efficace : les faux positifs à structure spectrale normale sont éliminés ;
- on conserve les vraies anomalies.

Cas CRM, CVS, IBM... : rappel nul – les anomalies y sont des dérives lentes, invisibles à la moyenne/variance à court terme.



Synthèse du pipeline

Étape	Outil	Anomalies détectées	Fondement
1a	Moyenne glissante	Pics, sauts de niveau	Bienaymé-Tchebychev
1b	Variance glissante	Sauts de volatilité	Idem
2	Spectre de Fourier	Structure fréquentielle anormale	Wiener-Khinchin
3	Intersection de fenêtres	Localisation temporelle	Propriété d'intersection

Résultat principal

L'étape 2 **réduit fortement** les fausses alarmes tout en conservant les vraies anomalies. Sur NAB realTweets : rappel $\geq 50\%$ pour la plupart des tickers, avec un gain net sur la précision.

Limites

- Les seuils (k, τ) dépendent de W et H.
- Hypothèse de stationnarité locale.
- Rappel nul pour les anomalies lentes (CRM, CVS...).

Perspectives – Stationnarité d'ordre 2 (extension naturelle)

Limite identifiée : une dérive lente ne modifie pas $\hat{\mu}$ ni $S(f)$ à court terme, mais change $R(\tau)$ pour des délais τ longs.

Outil naturel : autocorrélation empirique
Pour une fenêtre A, la fonction d'autocorrélation empirique est :

$$\hat{R}_A(\tau) = \frac{1}{W} \sum_{t=0}^{W-\tau-1} \big(x_A(t) - \hat{\mu}_A\big)\big(x_A(t+\tau) - \hat{\mu}_A\big)$$

Comparer $\hat{R}_A$ à la référence $\hat{R}_{\text{ref}}$ permettrait de détecter les changements de régime de corrélation.

Lien avec Wiener-Khinchin

Comparer $\hat{R}_A$ et $\hat{R}_{\text{ref}}$ revient à comparer les spectres normalisés de façon plus fine que la distance euclidienne. Ce serait l'extension naturelle du projet (étape 4).

Merci

Questions ?

Code : `fig.py` + `pipeline.py`
Données : NAB realTweets (`github.com/numenta/NAB`)